## **Chapter 8**

矩阵-向量乘

#### 章节目标

- 复习矩阵-向量乘法
- 分发数据以满足计算
- 基于不同数据分解的并行算法

#### 大纲

- 串行算法及其复杂性
- 三个并行程序的设计、分析和实现
  - 按行分块
  - 按列分块
  - 棋盘式分块

# 串行算法

2			4	
3				
4				×
3	0	2	0	

	1		9
<			
		=	
	1		11

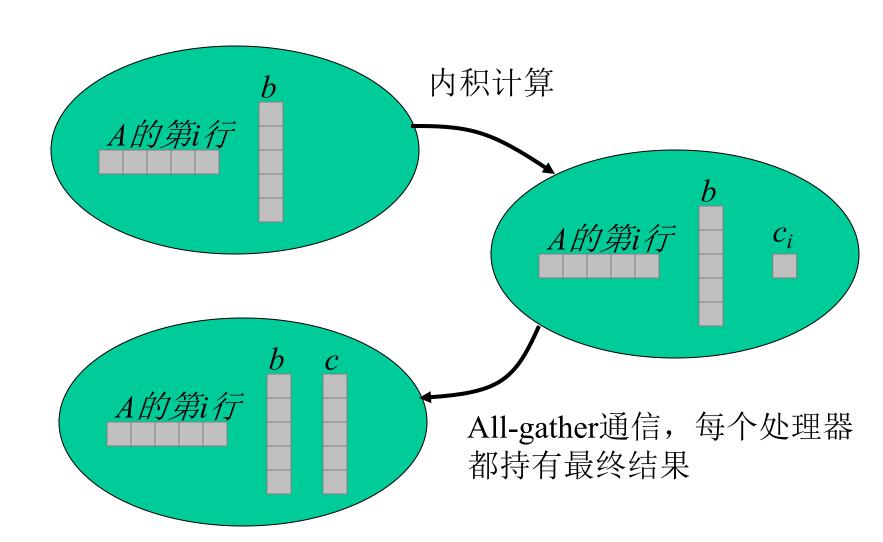
## 存储向量

- 在进程间划分向量元素
- 复制向量元素
- 向量复制是可接受的:相比矩阵的*n*<sup>2</sup>个元素,向量只有n个元素。

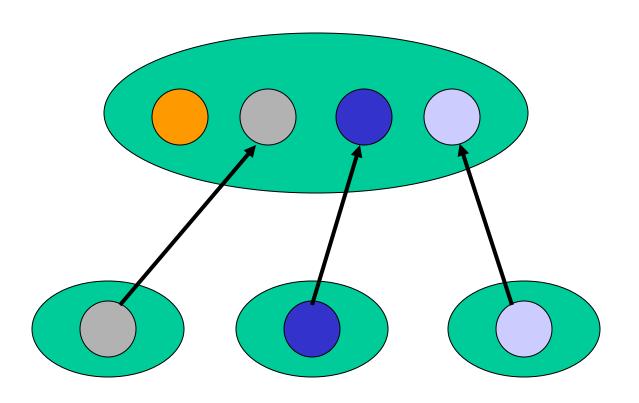
## 算法一:按行分块

- 通过域分解划分
- 每个任务存储
  - 对应矩阵的行
  - 整个向量

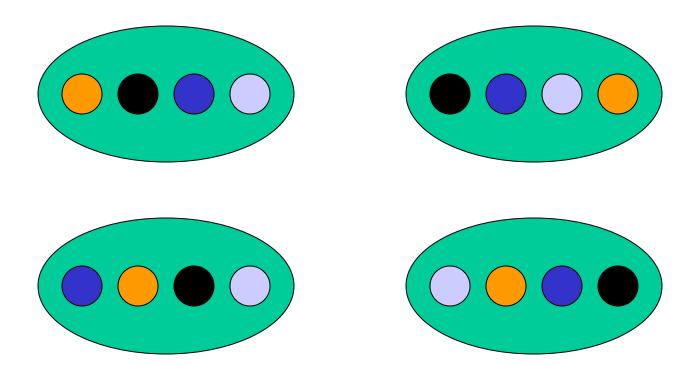
### 算法示意



### **Gather**



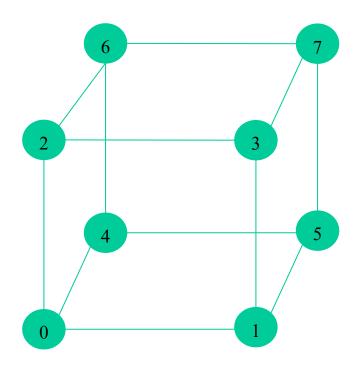
## **All-gather**



### 聚合和映射

- 静态的任务数量
- 有规律的通信模式( all-gather )
- 每个任务的计算时间是恒定的
- 策略:
  - 行聚合
  - 每个行组对应一个任务

## All gather通信时间复杂度分析



$$\sum_{i=1}^{\log p} \left( \lambda + \frac{2^{i-1}n}{\beta p} \right) = \lambda \log p + \frac{n(p-1)}{\beta p}$$

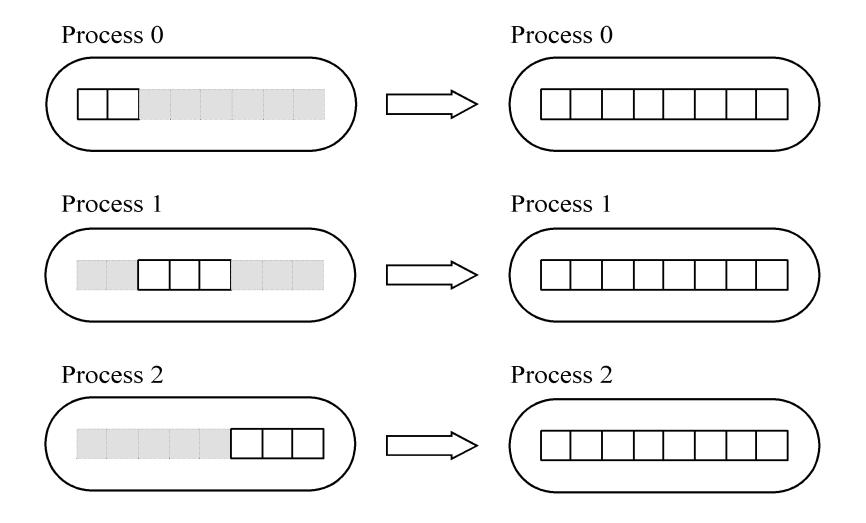
### 算法时间复杂度分析

- 串行算法复杂度: Θ(n²)
- 并行算法的计算复杂度:  $\Theta(n^2/p)$
- all-gather的通信复杂度: ⊕(log *p + n*)
- 总体复杂度: Θ(n²/p + n + log p)

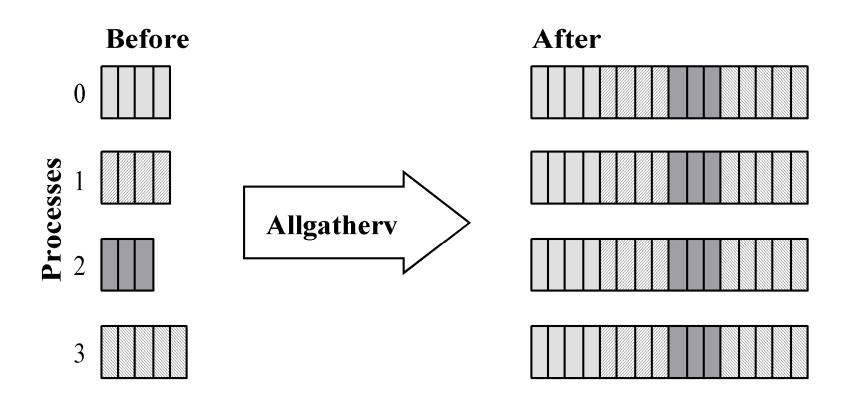
### 等效率分析

- 顺序时间复杂度: Θ(n²)
- 唯一的并行开销是all-gather
  - 当n很大时,消息传输时间支配着消息延迟
  - 并行通信时间: Θ(n)
- $n^2 \ge Cpn \Rightarrow n \ge Cp$  and  $M(n) = n^2$  $M(Cp)/p = C^2p^2/p = C^2p$
- 系统的可扩展性不高

## 结果向量拼接



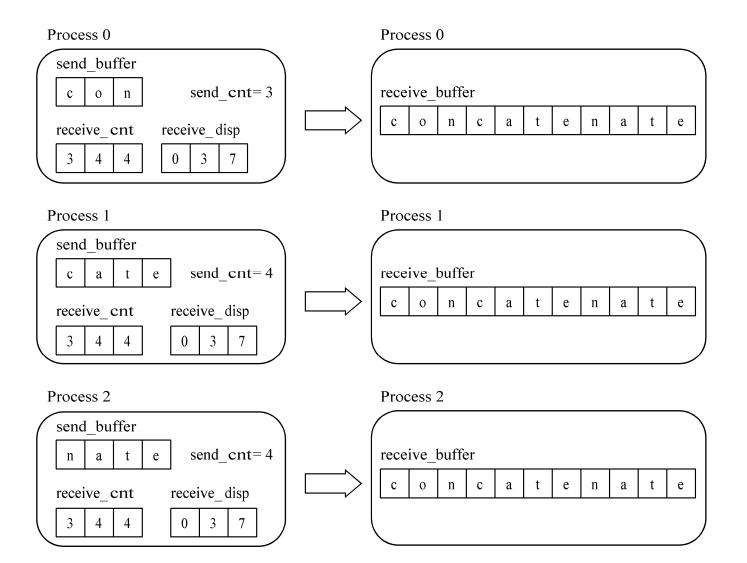
## **MPI\_Allgatherv**



## MPI\_Allgatherv

```
int MPI Allgatherv (
   void
                *send buffer,
   int
                 send cnt,
  MPI Datatype send type,
                *receive buffer,
  void
                *receive cnt,
   int
                *receive disp,
   int
  MPI Datatype receive type,
  MPI Comm
            communicator)
```

## MPI\_Allgatherv示意



# 示例代码 create\_mixed\_xfer\_arrays

- 第一个数组 count
  - 每个进程贡献多少个元素
  - 使用BLOCK\_SIZE宏确定每个进程负责的矩阵行数
- 第二个数组 disp
  - 每个进程块的起始位置
  - 假设块按进程号(rank)排列

#### create\_mixed\_xfer\_arrays

```
void create_mixed_xfer_arrays (
 int id, /* IN - Process rank */
  int p,
              /* IN - Number of processes */
  int n, /* IN - Total number of elements */
  int **count, /* OUT - Array of counts */
  int **disp) /* OUT - Array of displacements */
 int i;
  *count = my_malloc (id, p * sizeof(int));
  *disp = my_malloc (id, p * sizeof(int));
   (*count)[0] = BLOCK_SIZE(0,p,n);
   (*disp)[0] = 0;
 for (i = 1; i < p; i++) {
      (*disp)[i] = (*disp)[i-1] + (*count)[i-1];
      (*count)[i] = BLOCK_SIZE(i,p,n);
```

#### 运行时间

- χ: 内积循环迭代时间
- 计算时间: χ n n/p
- All-gather需要 [log *p*] 消息,延迟λ
- 传送的向量元素总数:
   n(2<sup>[log p]</sup>-1) / 2<sup>[log p]</sup>
- 总执行时间:  $\chi \ln n/p + \chi \log p + \ln(2^{\lceil \log p \rceil} 1)$  /  $(2^{\lceil \log p \rceil}\beta)$

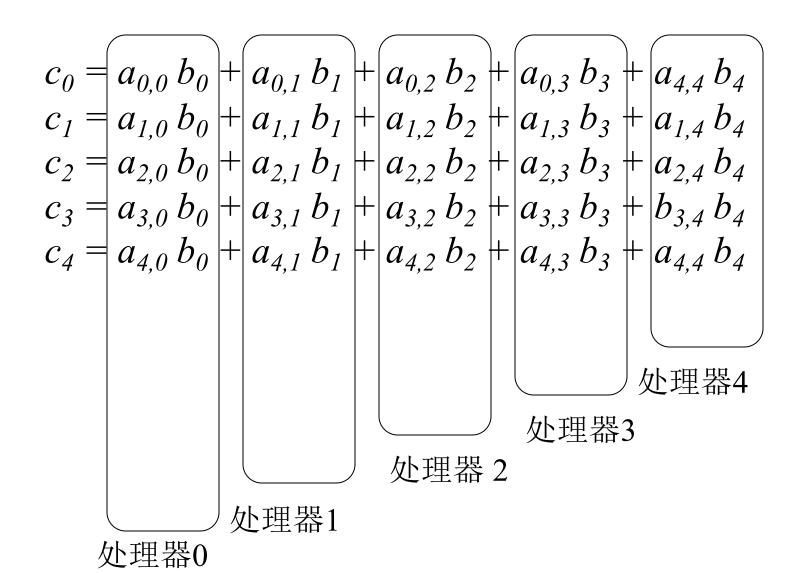
## 基准测试结果

	Execution	on Time (msec)		
p	Predicted	Actual	Speedup	Mflops
1	63.4	63.4	1.00	31.6
2	32.4	32.7	1.94	61.2
3	22.3	22.7	2.79	88.1
4	17.0	17.8	3.56	112.4
5	14.1	15.2	4.16	131.6
6	12.0	13.3	4.76	150.4
7	10.5	12.2	5.19	163.9
8	9.4	11.1	5.70	180.2
16	5.7	7.2	8.79	277.8

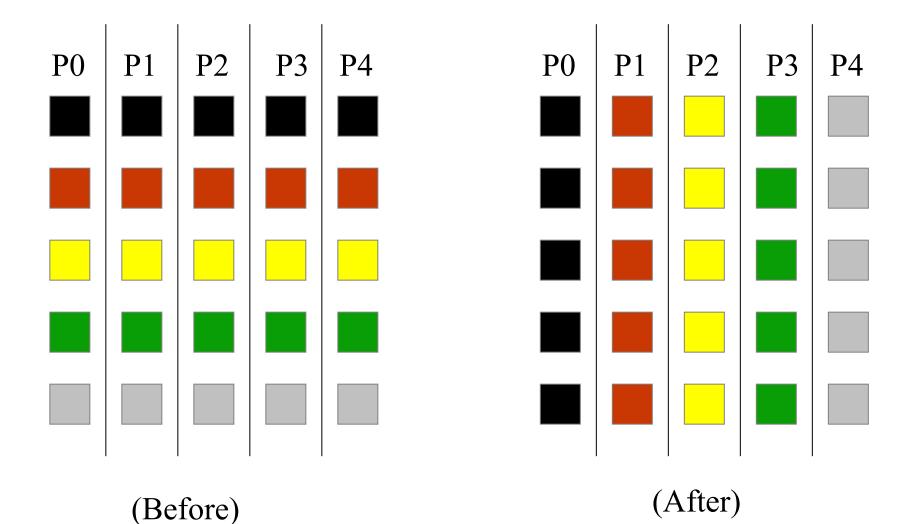
## 算法二:按列分块

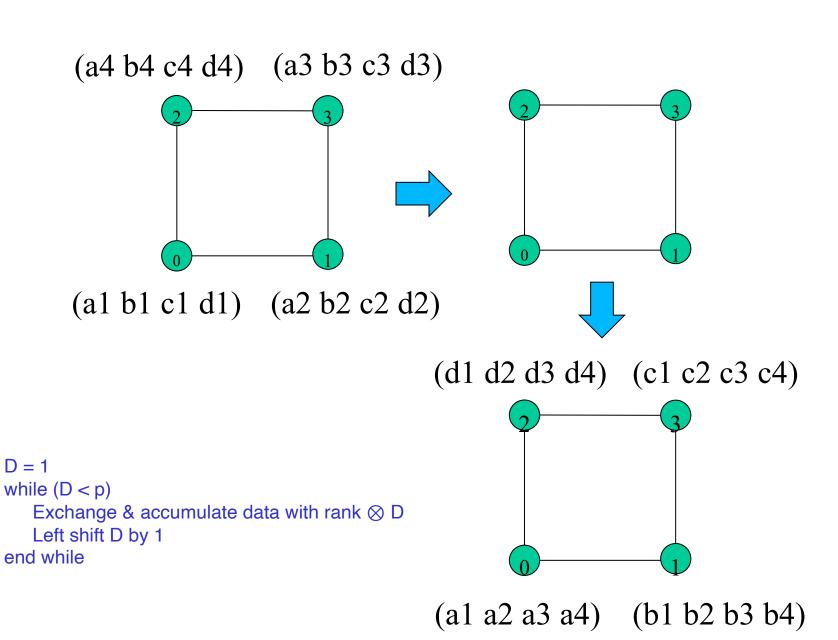
- 基于数据域的分解划分
- 每个任务存储
  - 矩阵的一列
  - 向量元素

#### 矩阵-向量乘法



## All-to-all Exchange

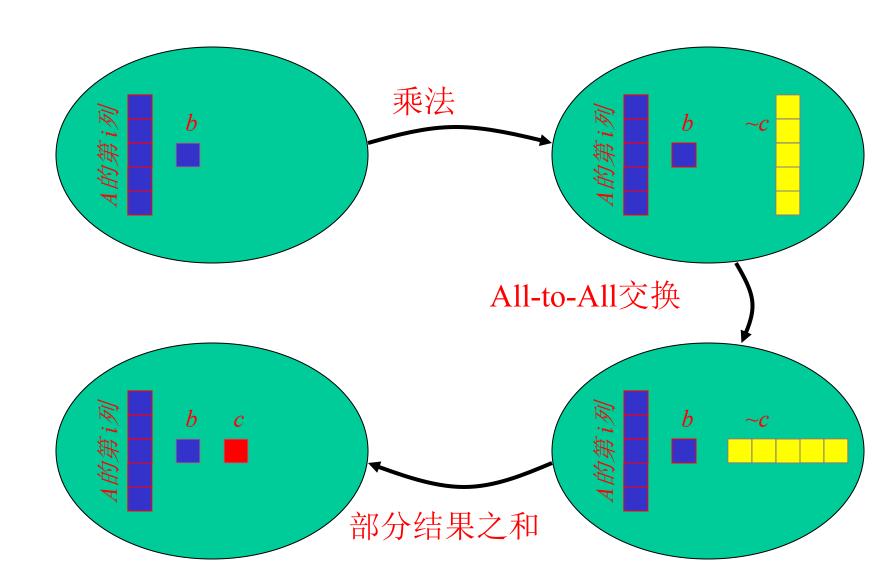




## All-to-all Exchange通信复杂度

- 在 log p 的每一阶段,所有节点都与其他 节点交换一半的数据;
- 在任何时候都只发送P/2条信息;
- 发送和接收的元素总数为 $n \log p$ ;
- 通信复杂度: O(n log p)

## 算法示意



#### 聚合和映射

- 静态的任务数量
- 正则通信模式((all-to-all)
- 每个任务的计算时间是恒定的
- 策略:
  - 聚合列的群组
  - 每个MPI进程创建一个任务

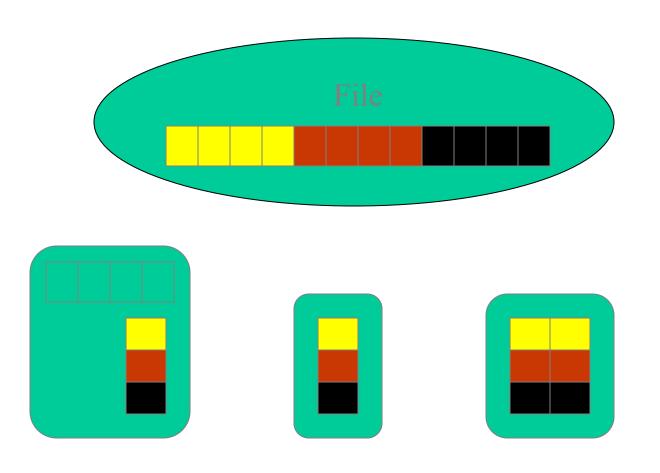
#### 复杂度分析

- 串行算法复杂度: Θ(n²)
- 并行算法的计算复杂度:  $\Theta(n^2/p)$
- 全对全的通信复杂度:  $\Theta(nlog p)$
- 总体复杂度: Θ(n²/p + nlog p)

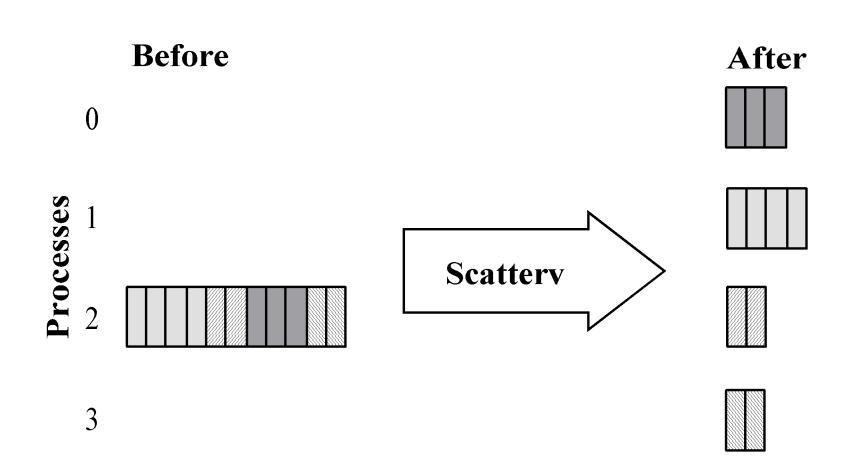
#### 等效性分析

- 串行时间复杂度: Θ(n²)
- 只有all-to-all消息的并行开销
  - 当n很大时,消息传输时间支配着消息延迟
  - 并行通信时间: Θ(nlog(p))
- $n^2 \ge Cpnlog(p) \Rightarrow n \ge Cplog(p)$
- 可扩展性函数高于rowwise算法:  $C^2p$

## 数据分发-按列存储



## **MPI\_Scatterv**



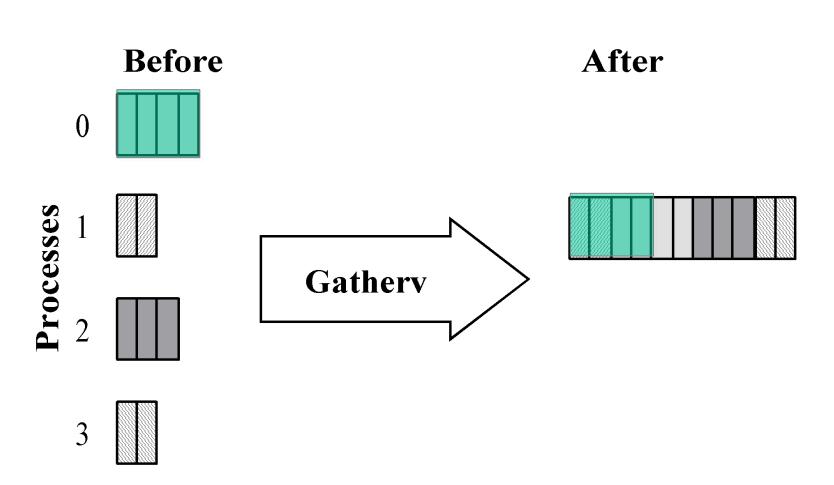
#### MPI\_Scatterv接口

```
int MPI Scattery (
   void
                 *send buffer,
                 *send cnt,
   int
                 *send disp,
   int
   MPI Datatype send type,
                 *receive buffer,
   void
                  receive cnt,
   int
   MPI Datatype receive type,
   int
                  root,
                  communicator)
   MPI Comm
```

## 打印分布于各个处理器的按列分布矩阵

- 数据运动与我们读取矩阵时相反
- 用 "聚集 "取代 "分散"
- 使用 "v"变体,因为不同的进程负责了不同数量的列

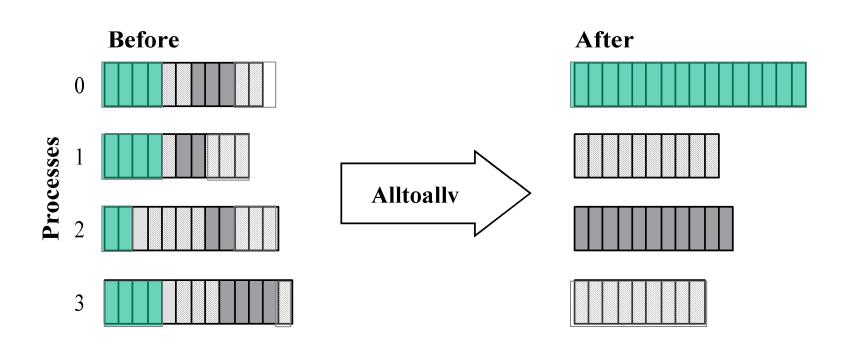
## 函数 MPI\_Gatherv



#### MPI\_Gatherv的接口

```
int MPI Gatherv (
   void
                 *send buffer,
                  send cnt,
   int
   MPI Datatype send type,
                 *receive buffer,
   void
   int
                 *receive cnt,
                 *receive disp,
   int
   MPI Datatype receive type,
   int
                  root,
                 communicator)
   MPI Comm
```

# 函数 MPI\_Alltoallv



#### MPI\_Alltoallv的接口

```
int MPI Alltoallv (
  void
                *send buffer,
                *send cnt,
   int
   int
                *send disp,
  MPI Datatype send type,
                *receive buffer,
  void
                *receive cnt,
   int
   int
                *receive disp,
  MPI Datatype receive type,
             communicator)
  MPI Comm
```

#### 运行时间

- χ:内积循环迭代时间
- 计算时间: χ n n/p
- All-gather 需要 p-1 消息, 每个消息长度为n/p
- 每个元素为8字节
- 总执行时间:  $\chi n n/p + (p-1)(\lambda + (8n/p)/\beta)$

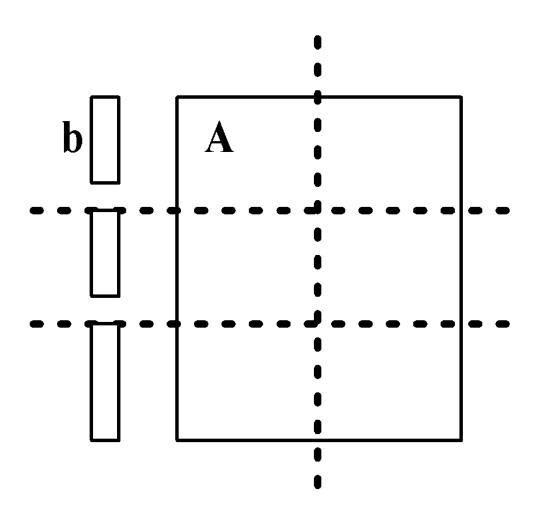
# Benchmarking 结果

	Execution	on Time (msec)		
p	Predicted	Actual	Speedup	Mflops
1	63.4	63.8	1.00	31.4
2	32.4	32.9	1.92	60.8
3	22.2	22.6	2.80	88.5
4	17.2	17.5	3.62	114.3
5	14.3	14.5	4.37	137.9
6	12.5	12.6	5.02	158.7
7	11.3	11.2	5.65	178.6
8	10.4	10.0	6.33	200.0
16	8.5	7.6	8.33	263.2

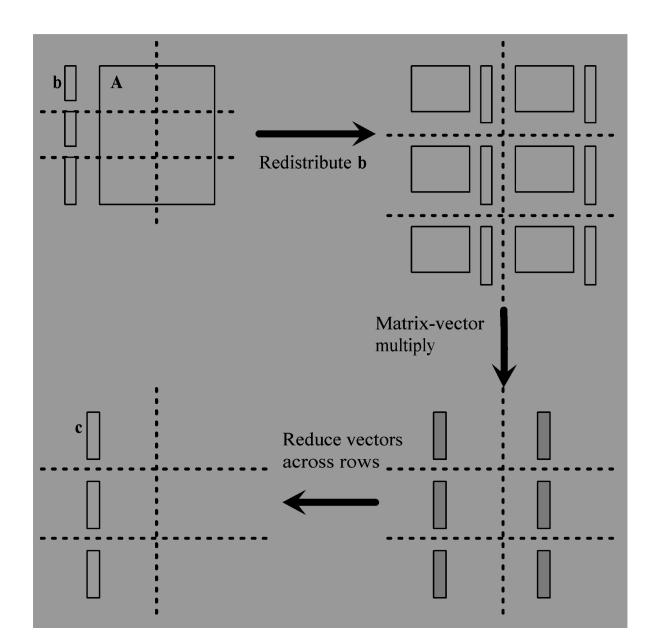
# 算法三:棋盘块分解

- 将矩阵 A 的每个元素与一个原始任务关联起来,
- 每个原始任务执行一次乘法运算。
- 将原始任务聚合成矩形块,
- 进程形成 2-D 网格,
- 向量b在网格的第一列进程中按块分布

# 聚合后的任务



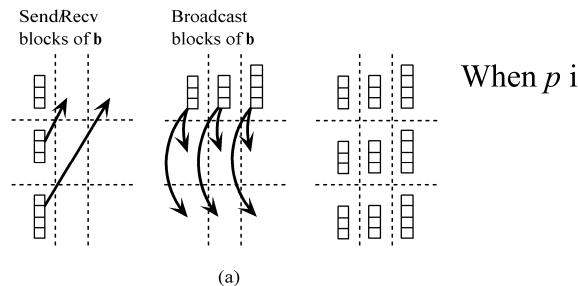
# 算法的各个阶段



#### 重分配向量b

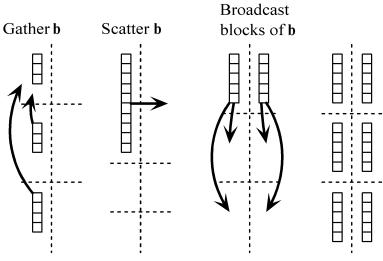
- 第一步:将 b 从第一行进程移动到第一列进程
  - 如果 p 是平方数
    - 第一列/第一行进程发送/接收部分 b
  - 如果 p 不是平方数
    - 在进程 0,0 上 gather b
    - 进程 0,0 将其 scatter 到第一行进程
- 第二步:第一行进程在列内广播 b

## 重分配向量b



When p is a square number

When *p* is not a square number



(b)

## 复杂度分析

- 假设p是平方数
  - 如果网格是 1 × p,则演变为按列块条带。
  - 如果网格是 p × 1,则演变为按行块条带。

#### 复杂度分析

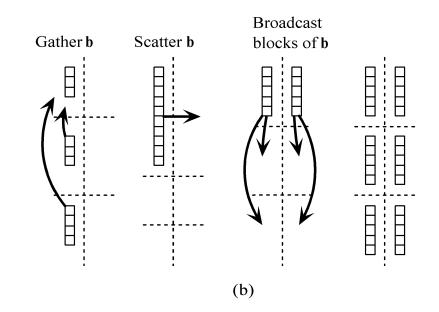
- 每个进程执行的计算: Θ(n²/p)
- 重分配 **b**:  $\Theta(n/\sqrt{p} + \log p(n/\sqrt{p})) = \Theta(n \log p(n/\sqrt{p}))$
- 规约:⊕(n log p / √p)
- 总体并行复杂度:
   Θ(n²/p + n log p / √p)

#### 等效性分析

- 串行复杂度: Θ(n²)
- 并行通信复杂度:  $\Theta(n \log p / \sqrt{p})$
- 等效性函数:  $n^2 \ge Cn \sqrt{p} \log p \Rightarrow n \ge C \sqrt{p} \log p$  $M(C\sqrt{p} \log p)/p = C^2 p \log^2 p/p = C^2 \log^2 p$
- 这个系统比前两个实现更具可扩展性。

## 创建通信域

- 进程子集的四种集合通信:
  - 当 p 不是平方数时,虚拟进程网格的第一列进程参与聚集向量 b 的通信。
  - 当 p 不是平方数时,虚拟进程网格的第一行进程参与切分向量 b 的通信。
  - 每个第一行进程将其 b 块广播给虚拟进程网格中同一列的其他进程
  - 网格中的每一行进程执行独立的求和规约,生成在第一列进程中的向量 c。



#### 创建通信域

- · 在虚拟的 2-D 网格中使用进程
- 创建一个自定义通信域来实现
- 集合通信涉及通信域中的所有进程
- 需要在进程子集之间进行广播、规约
- 为同一行或同一列中的进程创建通信域

## 通信域包含什么?

- 进程组
- 上下文
- 属性
  - 拓扑结构(让我们以另一种方式寻址进程)
  - 其他我们不考虑的内容。

## 通信域的拓扑结构

- 拓扑结构可以将寻址模式与进程关联起来
- 拓扑结构在本质上是虚拟的,因为它们不受处理器的实际组织方式限制
- 拓扑结构的两种类型
  - 笛卡尔(网格)
  - \_ 图

# 创建虚拟2-D网格进程

- MPI\_Dims\_create
  - 输入参数
    - 网格中的总进程数
    - 网格维数
  - 返回每个维度的进程数量
- MPI\_Cart\_create
  - 创建具有笛卡尔拓扑结构的通信域

#### **MPI\_Dims\_create**

```
int MPI Dims create (
   int nodes,
       /* Input - Procs in grid */
   int dims,
       /* Input - Number of dims */
   int *size)
       /* Input/Output - Size of
          each grid dimension */
```

#### MPI\_Cart\_create

```
int MPI Cart create (
  MPI Comm old comm, /* Input - old communicator */
   int dims, /* Input - grid dimensions */
   int *size, /* Input - # procs in each dim */
   int *periodic,
       /* Input - periodic[j] is 1 if dimension j
         wraps around; 0 otherwise */
   int reorder,
       /* 1 if process ranks can be reordered */
  MPI Comm *cart comm)
       /* Output - new communicator */
```

# Using MPI\_Dims\_create and MPI\_Cart\_create

```
MPI Comm cart comm;
int p;
int periodic[2];
int size[2];
size[0] = size[1] = 0;
MPI Dims create (p, 2, size);
periodic[0] = periodic[1] = 0;
MPI Cart create (MPI COMM WORLD, 2, size,
                 1, &cart comm);
```

#### 与网格相关的实用函数

- MPI\_Cart\_rank
  - 给定笛卡尔通信域中进程的坐标,返回进程序号
- MPI\_Cart\_coords
  - 给定笛卡尔通信域中进程的排名,返回进程坐标

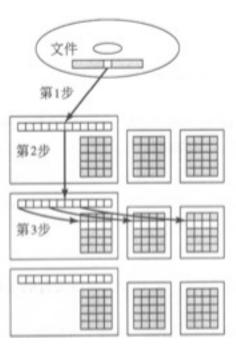
## **Header for MPI\_Cart\_rank**

## **Header for MPI\_Cart\_coords**

```
int MPI Cart coords (
  MPI Comm comm,
      /* In - Communicator */
   int rank,
      /* In - Rank of process */
   int dims,
      /* In - Dimensions in virtual grid */
   int *coords)
      /* Out - Coordinates of specified
         process in virtual grid */
```

#### read\_checkerboard\_matrix

```
void read checkerboard matrix (char *s, void ***subs, void
**storage, MPI Datatype dtype, int *m, int *n, MPI Comm
grid_comm) {
   .....
   int dest id; /* Rank of receiving proc */
   int dest coord[2]; /* Process coords */
   int grid id; /* Process rank */
    for ( i=0; i<m; i++) {
          dest coord[0]=BLOCK OWNER(i,r,m);
          dest coord[1]=1;
          MPI Cart rank(grid comm, dest coord, &dest id);
          if (qrid id==0){
               /* read matrx row 'i'*/
               /* send matrix row I to process dest_id */
          }else if (grid-_id==dest_id){
               /*receive matrix row I form process 0*/
          }
```



# MPI\_Comm\_split

- 将通信域中的进程划分为一个或多个子组
- 为每个子组构建一个通信域
- 允许每个子组中的进程执行自己的集合通信
- 对于按列 scatter 和按行 reduce 是必需的

# **Header for MPI\_Comm\_split**

```
int MPI Comm split (
  MPI Comm old comm,
      /* In - Existing communicator */
   int partition, /* In - Partition number */
  int new rank,
      /* In - Ranking order of processes
         in new communicator */
  MPI Comm *new comm)
      /* Out - New communicator shared by
         processes in same partition */
```

# **Example: Create Communicators for Process Rows**

```
MPI Comm grid comm; /* 2-D process grid */
MPI Comm grid coords[2];
         /* Location of process in grid */
MPI Comm row comm;
               /* Processes in same row */
MPI Comm split (grid comm, grid coords[0],
   grid coords[1], &row comm);
```

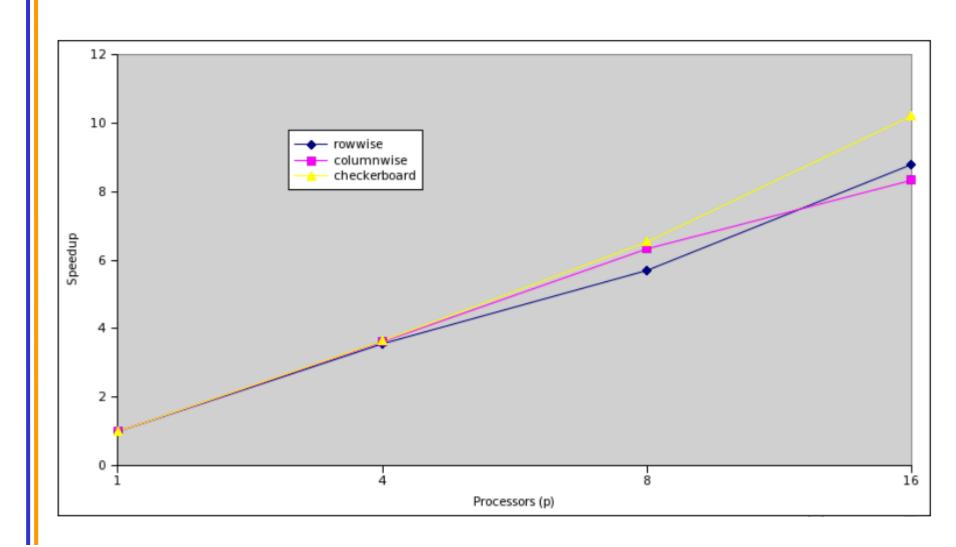
#### 运行时间

- 计算时间:  $\chi \lceil n/\sqrt{p} \rceil \lceil n/\sqrt{p} \rceil$
- 假定 p 是一个平方数
- 重分配 **b** 
  - 发送/接收: λ + 8 [n/√p] / β
  - 广播: log  $\sqrt{p}$  (λ + 8 $\lceil n/\sqrt{p} \rceil$  / β)
- 规约:  $\log \sqrt{p} (\lambda + 8 \lceil n/\sqrt{p} \rceil / β)$

# **Benchmarking**

Procs	Predicted (msec)	Actual (msec)	Speedup	Megaflops
1	63.4	63.4	1.00	31.6
4	17.8	17.4	3.64	114.9
9	9.7	9.7	6.53	206.2
16	6.2	6.2	10.21	322.6

# 三种算法对比



# 总结 (1/3)

- 矩阵分解⇒ 通信
  - 按行块: all-gather
  - 按列块: all-to-all exchange
  - 棋盘块: gather, scatter, broadcast, reduce
- 三种算法: 消息数量大致相同
- 每个进程传输的元素数量不同
  - 前两种算法:  $\Theta(n)$  元素 / 进程
  - 棋盘算法: Θ(n/√p) 元素/进程
- 棋盘块算法具有更好的可扩展性

# 总结 (2/3)

- 使用笛卡尔拓扑结构的通信域
  - 创建
  - 通过进程序号或坐标识别进程
- 对通信域进行细分
  - 允许在进程子集之间进行集合操作

# 总结 (3/3)

- 并行程序及其支持函数比C语言对应部分要复杂 得多
- 需要编写额外的代码来读取、分发和打印矩阵和 向量
- 开发和调试这些函数很繁琐,也很困难
- 因此将这些函数进行泛化并放入库中以供重用是合理的。