CHAPTER 7 FLOYD'S ALGORITHM

(弗洛伊德算法)



学习目标

- 创建二维数组
- 思考 "粒度"问题
- 介绍点对点通信
- 读取和构建二维矩阵
- 分析计算和通信重叠时的性能

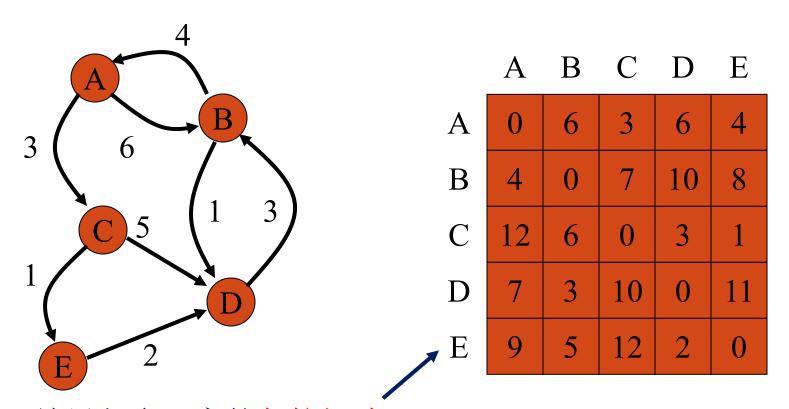


大纲

- 所有节点对之间的最短路径问题
- 动态二维数组
- 并行算法设计
- 点对点通信
- I/O块行矩阵I/O
- 分析和基准测试



所有节点对之间的最短路径问题



结果包含距离的邻接矩阵



弗洛伊德算法

```
for k \leftarrow 0 to n-1

for i \leftarrow 0 to n-1

for j \leftarrow 0 to n-1

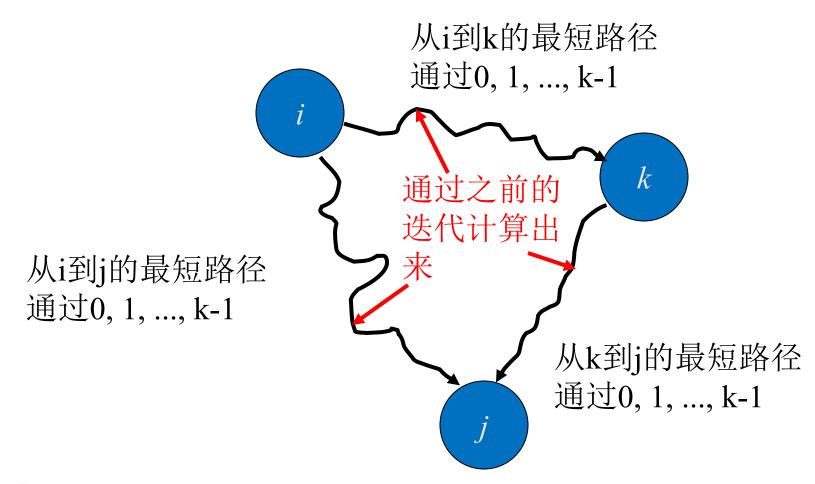
a[i,j] \leftarrow \min(a[i,j], a[i,k] + a[k,j])

endfor

endfor
```

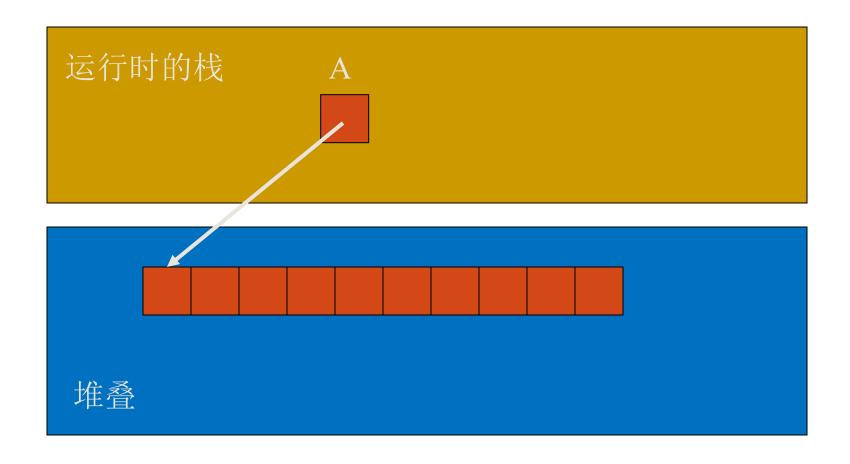


算法过程



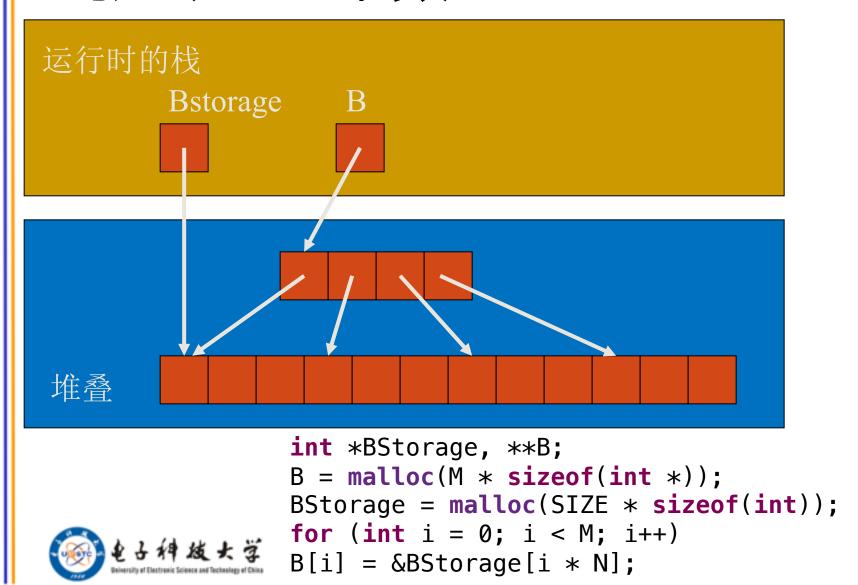


创建动态一维数组





创建动态二维数组



并行算法设计

- •划分
- 通信
- 聚合和映射



划分

- 领域划分还是功能划分?
 - 看一下伪代码
 - ■同一赋值语句执行了n3次
 - 没有功能并行
- 领域划分: 将矩阵A分成它的n2个元素

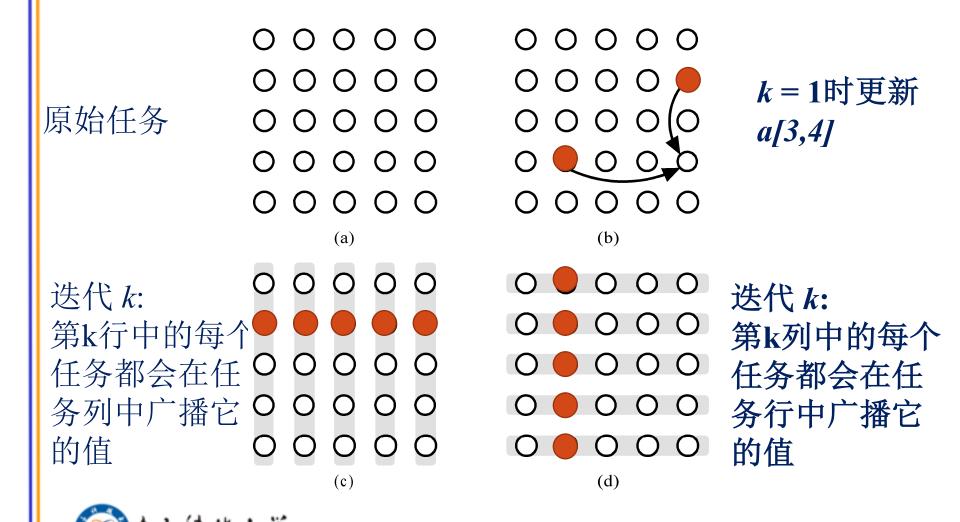
```
for k \leftarrow 0 to n-1

for i \leftarrow 0 to n-1

for j \leftarrow 0 to n-1

a[i,j] \leftarrow \min(a[i,j], a[i,k] + a[k,j])
endfor
endfor
```

通信



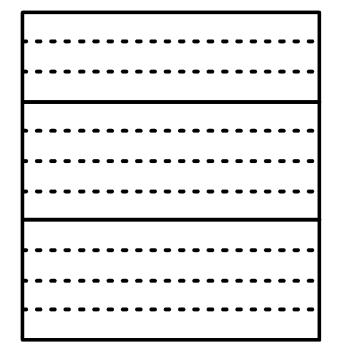
聚合和映射

- ■任务的数量: 静态
- ■任务之间的通信:结构化
- ■每个任务的计算时间: 恒定
- 策略:
 - 聚合任务以减少通信
 - 每个MPI进程创建一个任务

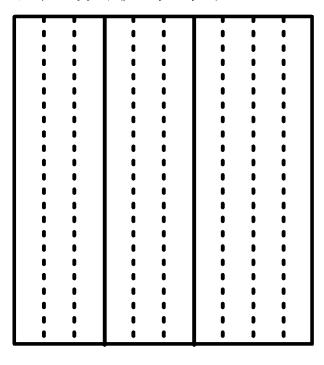


两种数据划分

行式块状条带化



列式块状条带化



(a)

(b)

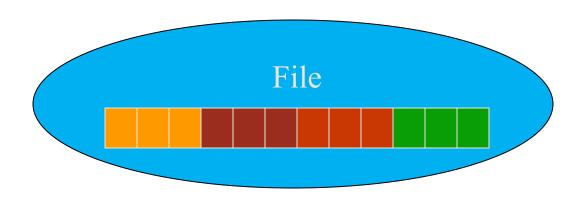


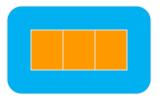
比较

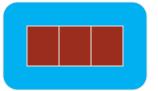
- 列式块状条带化
 - ■消除了列的广播
- 行式块状条带化
 - ■消除了行内广播
 - 从文件中读取矩阵更简单
- 选择行式块状条带化划分



文件输入











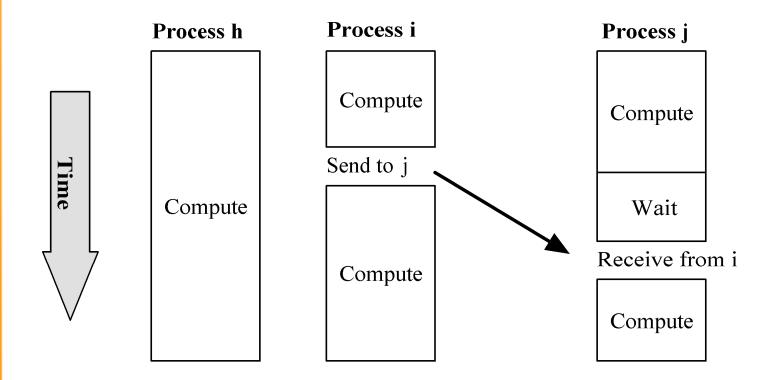


点对点通信

- 涉及到一对进程
- 一个进程发送一个消息
- 另一个进程接收该信息



发送/接收





函数 MPI_SEND

```
int MPI Send (
      void
                    *message,
      int
                     count,
      MPI Datatype datatype,
      int
                     dest,
      int
                     tag,
      MPI Comm
                     comm
```



逐数MPI_RECV

```
int MPI Recv (
      void
                    *message,
      int
                     count,
      MPI Datatype datatype,
      int
                     source,
      int
                     tag,
      MPI Comm
                     comm,
      MPI Status *status
```



发送/接收代码

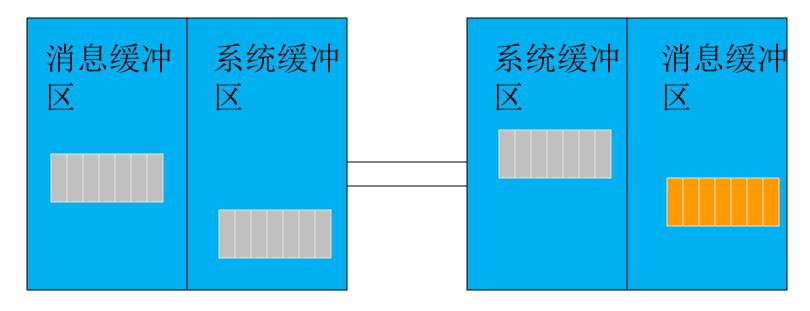
```
if (ID == j) {
                     接收在发送之前。
  Receive from I
                     为什么这样做?
if (ID == i) {
  Send to j
```



包括MPI_SEND和MPI_RECV

发送进程

接收进程



MPI_Send

MPI Recv



RETURN FROM MPI_SEND

- •函数阻断,直到消息缓冲区空闲
- •消息缓冲区空闲的时间是
 - ■消息被复制到系统缓冲区,或
 - •消息被传送
- 典型情况下
 - ■消息被复制到系统缓冲区
 - •传输重叠的计算



RETURN FROM MPI_RECV

- •函数阻断,直到信息进入缓冲区
- 如果信息没有到达,函数就不会返回



死锁

- ■死锁:等待一个永远不会成真的条件的过程
- 容易写出死锁的发送/接收代码
 - ■两个进程:都是先收后发
 - 发送标签与接收标签不一致
 - 进程向错误的目标进程发送消息



EXAMPLE 1

```
if (id == 0) {
MPI Recv (&b,...);
MPI Send (&a,...);
  c = (a + b)/2.0;
} else if (id == 1) {
MPI Recv (&a,...);
MPI Send (&b,...);
  c = (a + b)/2.0;
```

进程0阻塞等待来自1的信息,但1阻塞等待来自0的信息.

死锁!



EXAMPLE2-同样的场景

```
if (id ==0) {
    MPI_Send(&a, ... 1,MPI_COMM_WORLD);
    MPI_Recd(&b, ... 1, MPI_COMM_WORLD,&status);
    c = (a+b)/2.0;
}else if (id ==1) {
    MPI_Send(&a, ... 0,MPI_COMM_WORLD);
    MPI_Recd(&b, ... 0, MPI_COMM_WORLD,&status);
    c = (a+b)/2.0;}
```

两个进程在试图接收之前都发送了,但它们仍然陷入僵局。为什么?

标签是错误的。进程0试图接收一个1的标签,但进程1发送一个0的标签



发送/接收代码

```
if (ID == j) {
   Receive from i
if (ID == i) {
   Send to j
```

接收在发送之前。 为什么这样做?



MPI程序中的安全性

■一个依赖**MPI**提供缓冲的程序被认为是不安全的

这样的程序对于一些输入集可能运行没有问题, 但对于其他输入集可能会挂起或崩溃



MPI程序中的安全性

- •MPI标准允许MPI_Send以两种不同的方式行事:
 - ■它可以简单地将消息复制到MPI管理的缓冲区 并返回
 - •或者它可以阻塞,直到对MPI_Recv的匹配调用开始
- ●许多MPI的实现都设置了一个阈值,在这个阈值上,系统会从缓冲区切换到阻塞区。
 - ■相对较小的消息将由MPI_Send来缓冲
 - 较大的消息将导致其阻塞



- Case 1 从进程0向进程1发送一条很大的信息

如果在目的地没有足够的存储空间,发送必须等待用户提供存储空间(通过接收)

Process 0	Process 1	
Send(1)	Send(0)	
Recv(1)	Recv(0)	

■ Case 2 生产者和消费者

■ 如果流程0产生的大量信息需要发送给流程2,并且发送速度比接收速度快

	Process 0	Process 1	
	Send(1)	Recv(0)	



MPI_SSEND

- MPI标准定义的MPI_Send的一个替代方案
- ■额外的 "s "代表同步,MPI_Send保证阻塞直到匹配的接收开始



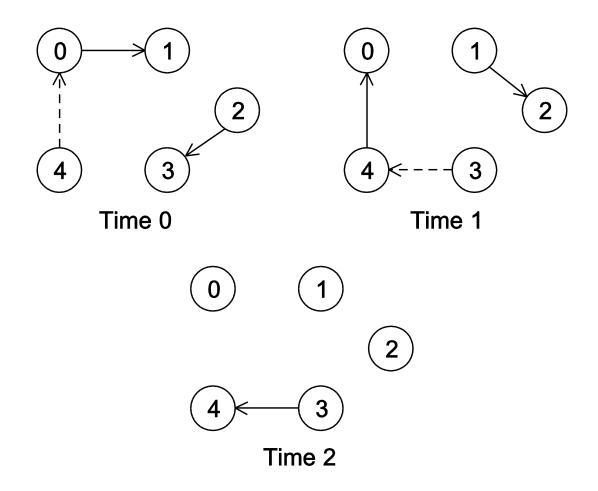
重组通信

```
\label{eq:mpi_send} \begin{split} \text{MPI\_Send(msg, size, MPI\_INT, (my\_rank+1) \% comm\_sz, 0, comm);} \\ \text{MPI\_Recv(new\_msg, size, MPI\_INT, (my\_rank+comm\_sz-1) \% comm\_sz,} \\ 0, comm, MPI\_STATUS\_IGNORE. \end{split}
```





五个进程的安全通信





MPI_SENDRECV

- •这是一个替代自己安排通信的方法
- ●在一个单一的调用中执行一个阻塞的发送和接收
- •目的地和源可以是相同或不同的
- ■特别有用的是MPI调度通信,这样程序就不会 挂起或崩溃



MPI_SENDRECV

```
int MPI_Sendrecv(
    void*
               send_buf_p /* in */,
               send_buf_size /*in */,
    int
    MPI_Datatype send_buf_type /* in */,
    int
                  /* in */,
             dest
               send_tag /*in */,
    int
           recv_buf_p /* out */,
    void*
            recv_buf_size /*in */,
    int
    MPI_Datatype recv_buf_type /*in */,
               source /*in */,
    int
               int
    MPI_Comm communicator /*in */,
    MPI_Status* status_p /* in */);
```



点对点通信VS集合通信

- •通信域中的所有进程必须调用相同的集体函数
 - ■例如,如果一个程序试图将一个进程上对 MPI_Reduce的调用与另一个进程上对 MPI_Recv的调用相匹配,则是错误的,而且,很可能程序会挂起或崩溃

点对点通信VS集合通信

- •每个进程传递给MPI集合通信的参数必须是 " 兼容的"
 - •例如,如果一个进程传入0作为dest_process,而另一个进程传入1,那么调用MPI_Reduce的结果是错误的,而且,程序很可能再次挂起或崩溃

点对点通信VS集合通信

•output_data_p参数只在dest_process上使用

然而,所有的进程仍然需要传入一个与 output_data_p相对应的实际参数,即使它只 是NULL



点对点通信VS集合通信

■点对点通信是在标签和通信域的基础上进行匹配

- 集合通信不使用标签
 - •它们只根据通信者和它们被调用的顺序来匹配



```
→ int main (int argc, char *argv[]) {
    dtype** a;
                    /* Doubly-subscripted array */
    dtype* storage; /* Local portion of array elements */
    int
           i, j, k;
    int
                    /* Process rank */
           id;
    int
                    /* Rows in matrix */
           m;
    int
                   /* Columns in matrix */
           n;
    int
                      /* Number of processes */
            p;
    double time, max time;
    void compute_shortest_paths (int, int, int**, int);
   MPI_Init (&argc, &argv);
   MPI_Comm_rank (MPI_COMM_WORLD, &id);
   MPI_Comm_size (MPI_COMM_WORLD, &p);
    read row striped matrix (argv[1], (void *) &a,
       (void *) &storage, MPI_TYPE, &m, &n, MPI_COMM_WORLD);
    if (m != n) terminate (id, "Matrix must be square\n");
    print_row_striped_matrix ((void **) a, MPI_TYPE, m, n,
      MPI COMM WORLD):
   MPI_Barrier (MPI_COMM_WORLD);
    time = -MPI_Wtime();
    compute_shortest_paths (id, p, (dtype **) a, n);
    time += MPI_Wtime();
   MPI_Reduce (&time, &max_time, 1, MPI_DOUBLE, MPI_MAX, 0,
      MPI COMM WORLD);
   if (!id) printf ("Floyd, matrix size %d, %d processes: %6.2f seconds\n",
       n, p, max_time);
    print_row_striped_matrix ((void **) a, MPI_TYPE, m, n,
      MPI COMM WORLD);
   MPI_Finalize();
```

```
void compute_shortest_paths (int id, int p, dtype **a, int n)
   int i, j, k;
   int offset; /* Local index of broadcast row */
   int root; /* Process controlling row to be bcast */
   int* tmp; /* Holds the broadcast row */
   tmp = (dtype *) malloc (n * sizeof(dtype));
   for (k = 0; k < n; k++) {
      root = BLOCK_OWNER(k,p,n);
      if (root == id) {
         offset = k - BLOCK_LOW(id,p,n);
         for (j = 0; j < n; j++)
            tmp[j] = a[offset][j];
      }
      MPI_Bcast (tmp, n, MPI_TYPE, root, MPI_COMM_WORLD);
      for (i = 0; i < BLOCK_SIZE(id,p,n); i++)</pre>
         for (j = 0; j < n; j++)
            a[i][j] = MIN(a[i][j],a[i][k]+tmp[j]);
   free (tmp);
```

计算复杂度

- 最内层循环的复杂度为 $\Theta(n)$
- •中间循环最多执行[n/p]次
- 外循环执行了n次
- 总体复杂度 $\Theta(n^3/p)$

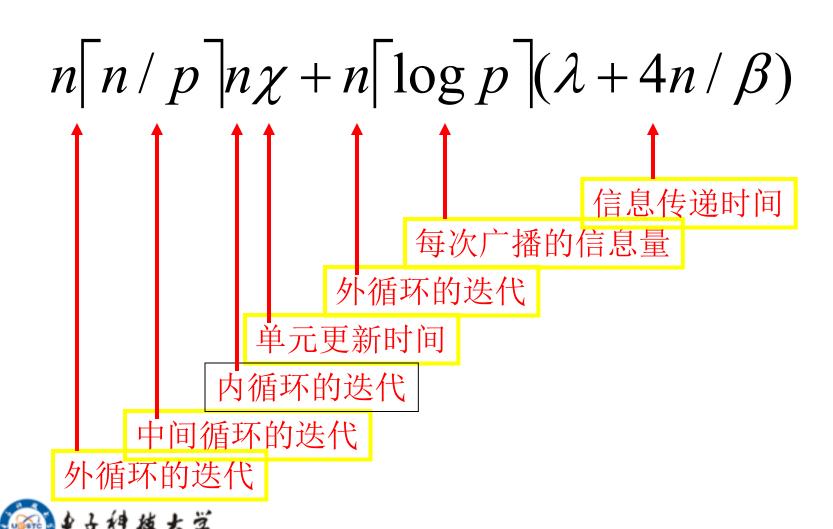


通信复杂度

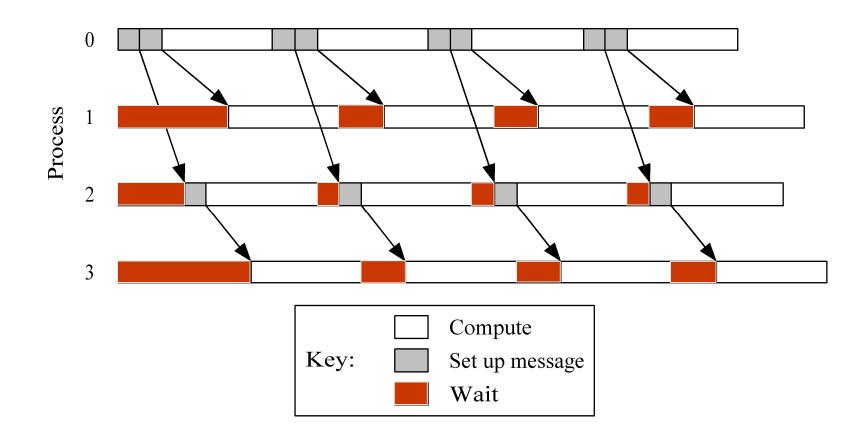
- 内循环中没有交流
- 中循环没有通信
- 外循环中的广播 复杂度为 $\Theta(n \log p)$
- 总体复杂度 Θ(n² log p)



执行时间表达式(1)

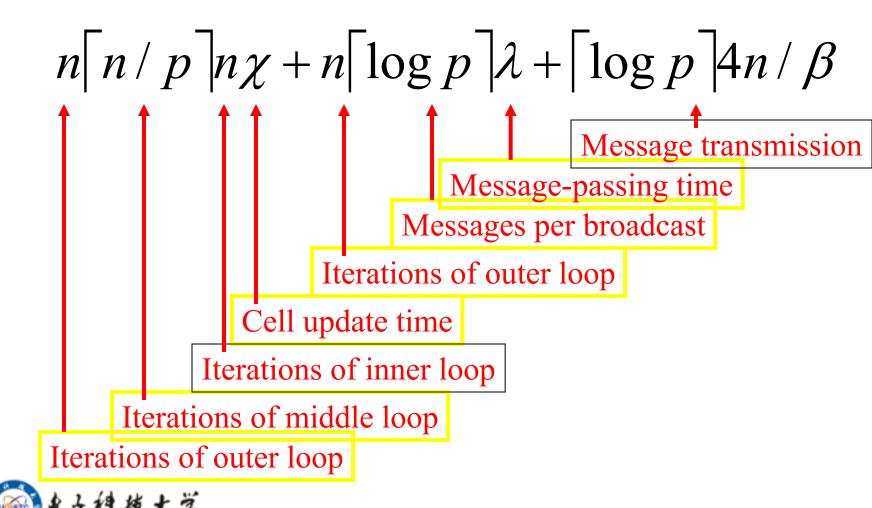


计算/通信叠加





执行时间表达式(2)



理论性能VS实际性能

	Execution Time (sec)	
Processes	Predicted	Actual
1	25.54	25.54
2	13.02	13.89
3	9.01	9.60
4	6.89	7.29
5	5.86	5.99
6	5.01	5.16
7	4.40	4.50
8	3.94	3.98



总结

- 两种矩阵划分法
 - •按行排列的块状划分
 - 按列排列的块状划分
- 分块发送/接收函数
 - MPI_Send
 - MPI_Recv
- 与计算重叠的通信

