

消息传递程序设计





学习目标

- ■了解MIPI程序如何执行
- ■熟悉基本的MPI功能

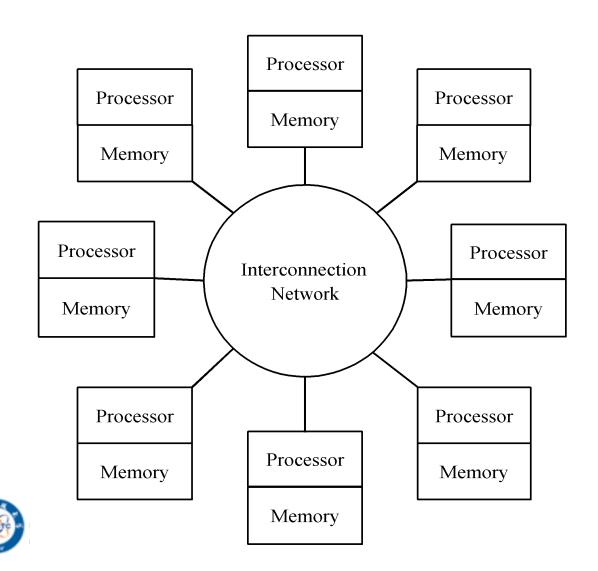


OUTLINE

- ■消息传递模型
- ■消息传递接口(MPI)
- ■编码MPI程序
- ■编译MPI程序
- ■运行MPI程序
- ■对MPI程序进行基准测试



消息传递模式



进程

- ■数量在启动时被指定
- ■在整个程序执行过程中保持不变
- ■所有执行相同的程序
- ■每个进程都有唯一的ID号
- ■交替进行计算和通信



消息传递接口(MPI)

■1980年代末:供应商专有系统

■1989: 橡树岭国家实验室开发了并行虚拟机(PVM)

■1992: MPI标准开始制定

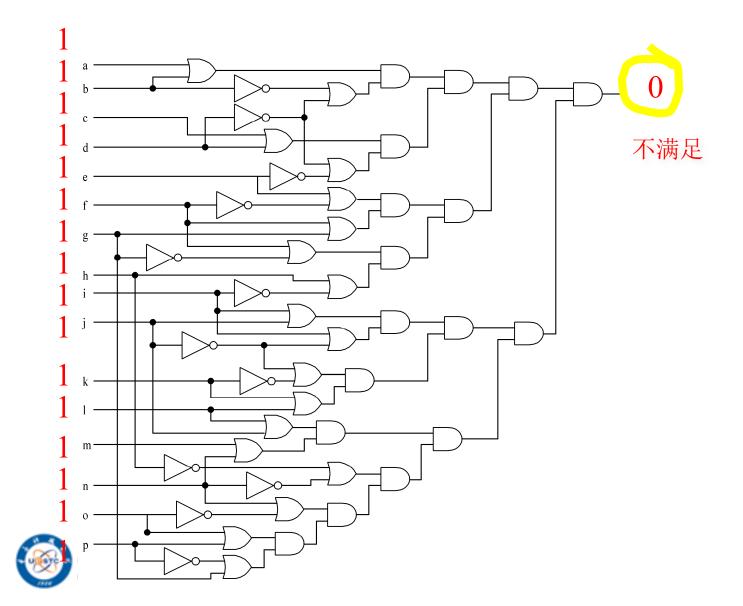
■1994: MIPI标准的1.0版发布

■1997: MIPI标准的2.0版发布

■当前: MIPI是事实上的消息传递接口工业标准



电路可满足性

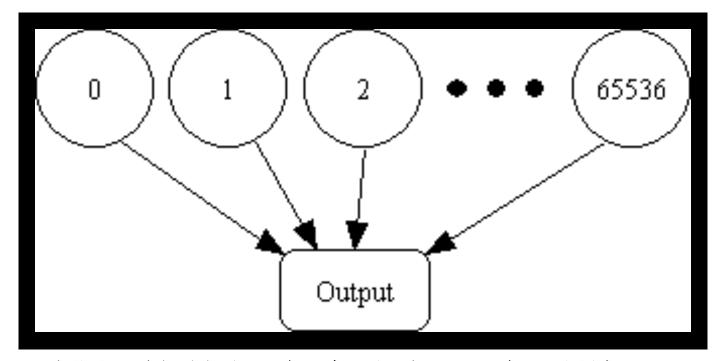


解决方法

- ■电路可满足性是NP-完全的
 - ■NP-完全问题:没有已知的算法可以在多项式时间内解决
- ■我们寻找所有的解决方案,通过穷举式搜索
- ■16 个输入 ⇒ 65,536 个组合来测试



划分和通信



■ 尴尬的并行:任务之间没有通道



聚合和映射

■并行算法的特性

- ◆固定的任务数
- ◆任务之间没有通信
- ◆每个任务需要的时间是可变的

■咨询映射策略决策树

◆以循环的方式将任务映射到处理器上



循环(交错)分配

- ■假设有p个进程
- ■每个进程得到每一个分配的第p个工作
- ■Example:有 5个进程和12个任务
 - P_0 : 0, 5, 10
 - P_1 : 1, 6, 11
 - P_2 : 2, 7
 - P_3 : 3, 8
 - $◆P_4$: 4, 9



程序设计

- ■程序将考虑16个布尔输入的所有65,536种组合
- ■组合以循环的方式分配给进程
- ■进程检查其每个组合
- ■如果它发现了一个可满足的组合,打印输出



包含的文件

- #include <mpi.h>
- **■MPI** header file

- #include <stdio.h>
- ■标准I/O头文件



局部变量

```
int main (int argc, char *argv[]) {
  int i;
  int id; /* Process rank */
  int p; /* Number of processes */
  void check_circuit (int, int);
```

- ■包括argc和argv:需要它们来初始化 MPI
- 为运行该程序的每个进程提供一份每个 变量的副本



初始化MPI

```
MPI_Init (&argc, &argv);
```

- ■每个进程调用的第一个MPI函数
- ■不一定是第一个可执行的语句
- ■允许系统进行任何必要的设置

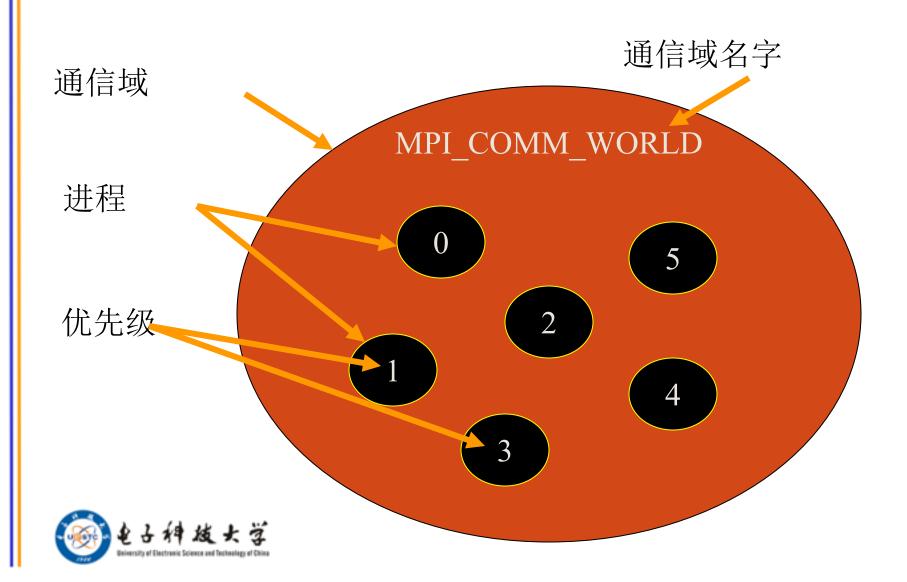


通信

- ■通讯域:不透明的对象,为进程提供消息传递的环境
- ■MPI COMM WORLD
 - ◆默认的通信域
 - ◆包括所有进程
- ■有可能创建新的通信域
 - ◆将在第8章中这样做



通信域(COMMUNICATOR)



确定进程的数量

MPI_Comm_size (MPI_COMM_WORLD, &p);

- ■第一个参数是通信域
- ■通过第二个参数返回的进程数



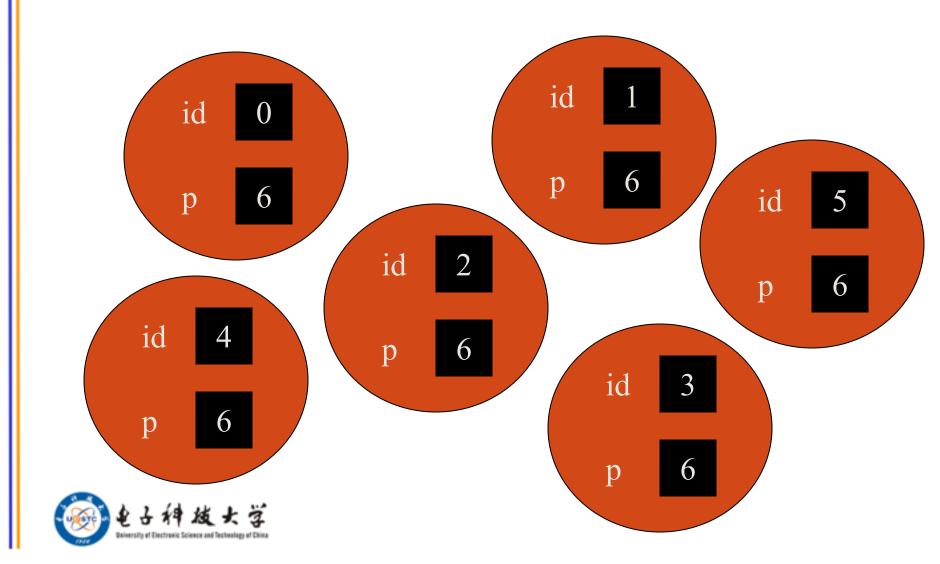
确定进程编号

```
MPI_Comm_rank (MPI_COMM_WORLD, &id);
```

- ■第一个参数是通信域
- ■通过第二个参数返回的处理优先级(范围为0,1,...,p-1)



自动变量的复制



外部变量呢?

```
int total;
int main (int argc, char *argv[]) {
   int i;
   int id;
   int p;
...
```

■ total变量存储在哪里?



循环分配计算任务

```
for (i = id; i < 65536; i += p)
    check_circuit (id, i);</pre>
```

- ■并行是在函数check_circuit之外
- ■它可以是一个普通的、顺序的函数



MPI调用结束

MPI_Finalize();

- ■在所有其他MPI库调用之后调用
- ■允许系统释放MPI资源



```
#include <mpi.h>
#include <stdio.h>
int main (int argc, char *argv[]) {
  int i;
  int id;
  int p;
  void check circuit (int, int);
  MPI Init (&argc, &argv);
  MPI Comm rank (MPI COMM WORLD, &id);
  MPI Comm size (MPI COMM WORLD, &p);
  for (i = id; i < 65536; i += p)
     check circuit (id, i);
  printf ("Process %d is done\n", id);
  fflush (stdout);
  MPI Finalize();
   return 0;
            在每一个printf()之后用fflush()
```

```
/* Return 1 if 'i'th bit of 'n' is 1; 0 otherwise */
#define EXTRACT BIT(n,i) ((n&(1 << i))?1:0)
void check circuit (int id, int z) {
   int v[16]; /* Each element is a bit of z */
   int i;
   for (i = 0; i < 16; i++) v[i] = EXTRACT BIT(z,i);
   if ((v[0] | v[1]) \& (!v[1] | !v[3]) \& (v[2] | v[3])
      && (!v[3] \mid | !v[4]) && (v[4] \mid | !v[5])
      && (v[5] | | |v[6]) && (v[5] | |v[6])
      && (v[6] \mid | v[15]) && (v[7] \mid | v[8])
      && (!v[7] \mid | !v[13]) && (v[8] \mid | v[9])
      && (v[8] \mid | v[9]) && (v[9] \mid | v[10])
      && (v[9] \mid | v[11]) && (v[10] \mid | v[11])
      && (v[12] \mid | v[13]) && (v[13] \mid | | v[14])
      && (v[14] \mid v[15]) {
      v[0], v[1], v[2], v[3], v[4], v[5], v[6], v[7], v[8], v[9],
         v[10], v[11], v[12], v[13], v[14], v[15]);
      fflush (stdout);
```

编译MPI程序

mpicc -O -o foo foo.c

- ■mpicc: 编译和连接C+MPI程序的脚本
- ■Flags:与C语言编译器含义相同
 - ◆-o 优化
 - ◆-o <file>—放置可执行文件的地方



运行MPI程序

- ■mpirun -np <exec> <arg1> ...
 - ◆-np —进程的数量
 - ◆<exec> 可执行程序
 - ◆<arg1> ...—命令行参数



指定主机处理器

- ■主目录中的.mpi-machines文件按照使用顺序列出了 主机处理器
- ■.mpi_machines文件内容示例

band01.cs.ppu.edu

band02.cs.ppu.edu

band03.cs.ppu.edu

band04.cs.ppu.edu



在I个CPU上执行

% mpirun -np 1 sat
0) 1010111110011001
0) 0110111110011001
0) 1010111111011001
0) 0110111111011001
0) 10101111110111001
0) 0110111110111001
0) 1110111110111001
Process 0 is done



在2个CPU上执行

% mpirun -np 2 sat 0) 0110111110011001 0) 0110111111011001 0) 0110111110111001 1) 1010111110011001 1) 1110111110011001 1) 1010111111011001 1) 1110111111011001 1) 1010111110111001 1) 1110111110111001 Process 0 is done Process 1 is done



在3个CPU上执行

% mpirun -np 3 sat 0) 0110111110011001 0) 1110111111011001 2) 1010111110011001 1) 1110111110011001 1) 1010111111011001 1) 0110111110111001 0) 1010111110111001 2) 0110111111011001 2) 1110111110111001 Process 1 is done Process 2 is done Process 0 is done



输出

- ■输出顺序只部分反映了并行计算机内部输出事件的顺序
- ■如果进程A打印两条信息,第一条信息会出现在第二条 之前
- ■如果进程A在进程B之前调用printf,不能保证进程A的信息会出现在进程B的信息之前



优化程序

- ■我们希望找到解决方案的总数
- ■将sum-reduction 放入程序中
- ■Reduction 是一种集体通信



改进

- ■修改函数check_circuit
 - ◆如果电路可以满足输入组合,则返回1
 - ◆否则返回0
- ■每个进程保留它所发现的可满足电路的本地计数
- ■在for循环之后进行还原



新的声明和代码

```
int count; /* Local sum */
int global count; /* Global sum */
int check circuit (int, int);
count = 0;
for (i = id; i < 65536; i += p)
   count += check circuit (id, i);
```



MPI_REDUCE()的原型

```
int MPI Reduce (
   void
                *operand,
                /* addr of 1st reduction element */
   void
                *result,
                /* addr of 1st reduction result */
   int
                count,
                /* reductions to perform */
  MPI Datatype type,
                /* type of elements */
  MPI Op
                operator,
                /* reduction operator */
   int
                root,
                /* process getting result(s) */
   MPI Comm
                comm
                /* communicator */
```

MPI DATATYPE选项

- ■MPI_CHAR
- ■MPI DOUBLE
- ■MPI FLOAT
- ■MPI INT
- ■MPI LONG
- ■MPI LONG DOUBLE
- ■MPI SHORT
- ■MPI UNSIGNED CHAR
- ■MPI UNSIGNED
- MPI_UNSIGNED_LONG
- MPI UNSIGNED SHORT

MPI OP选项

- ■MPI BAND
- ■MPI BOR
- ■MPI BXOR
- ■MPI LAND
- ■MPI LOR
- ■MPI LXOR
- ■MPI MAX
- ■MPI_MAXLOC
- ■MPI MIN
- ■MPI MINLOC
- ■MPI PROD
- ■MPI SUM



我们对MPI_REDUCE()的调用

```
MPI_Reduce (&count, &global_count, 1, 1, MPI_INT, MPI_SUM, 只有进程0会 0, 4到结果 MPI_COMM_WORLD);
```

if (!id) printf ("There are %d different solutions\n", global_count); 食品种技术等

执行第二个计划

```
% mpirun -np 3 seq2
0) 0110111110011001
0) 1110111111011001
1) 1110111110011001
1) 1010111111011001
2) 1010111110011001
2) 0110111111011001
2) 1110111110111001
1) 0110111110111001
0) 1010111110111001
Process 1 is done
Process 2 is done
Process 0 is done
There are 9 different solutions
```



程序性能测定

- ■MPI_Barrier—barrier同步化
- ■MPI_Wtick —定时器分辨率
- ■MPI_Wtime —当前时间



WALL-CLOCK目寸间VS CPU日寸间

■CPU时间(或处理时间)

- ◆是指CPU用于处理指令的时间.
- ◆用户时间 + 系统时间

■Wall-clock time (or wall time)

- ◆从一个任务开始到完成的时间流逝.
- ◆CPU时间,I/O时间,以及通信通道的延迟
- usr/bin/time



基准代码

```
double elapsed_time;
...
MPI_Init (&argc, &argv);
MPI_Barrier (MPI_COMM_WORLD);
elapsed_time = - MPI_Wtime();
...
MPI_Reduce (...);
elapsed_time += MPI_Wtime();
```

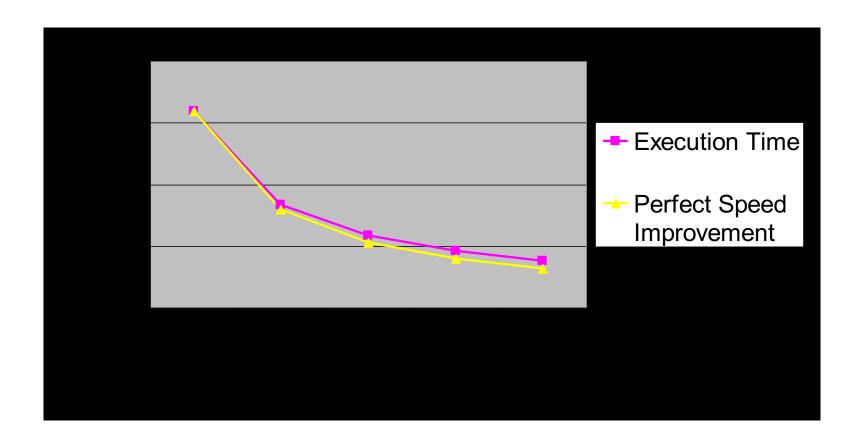


基准测试结果

Processors	Time (sec)
1	15.93
2	8.38
3	5.86
4	4.60
5	3.77



基准测试结果





总结 (1/2)

- ■消息传递编程自然地遵循任务/通道模型
- ■消息传递程序的可移植性
- ■MPI是最广泛采用的标准



总结 (2/2)

■引入MPI函数

- ◆MPI Init
- ♦MPI Comm rank
- ◆MPI Comm size
- MPI Reduce
- ◆MPI Finalize
- ◆MPI Barrier
- ◆MPI Wtime
- ◆MPI_Wtick

